

Junio24.pdf



Anónimo



Probabilidad y Estadística II



2º Grado en Ingeniería Informática



**Escuela Técnica Superior de Ingenieros Informáticos
Universidad Politécnica de Madrid**



[Accede al documento original](#)

Pásate a Gemini

Traslada tus preferencias de IA y
tu historial de chats a Gemini



 Contexto personal

 Importar dato
memorizado a Gemini

NUEVO

 Aplicaciones conectadas

 Tus enlaces públicos

Probabilidades y Estadística II

Examen miércoles 12 junio 2024 Soluciones — Examen final

Soluciones

Nombre:
Apellidos:
Grupo:

1. (2,5 puntos)

Quince estudiantes que deseaban hacer carreras de ingeniería se compararon con 15 estudiantes que deseaban hacer carreras de humanidades. La tabla 1 muestra las medias ($\bar{x}$) y cuasi-desviaciones-típicas (s) de las notas de lengua y matemáticas de los exámenes de EVAU para los dos grupos de estudiantes:

	Lengua	Matemáticas
Ingeniería	$\bar{x} = 446, s = 42$	$\bar{x} = 548, s = 57$
Humanidades	$\bar{x} = 534, s = 45$	$\bar{x} = 517, s = 52$

Tabla 1: Notas de lengua y matemáticas en la EVAU.

- (a) (1.5 puntos) Construye un intervalo de confianza del 95% para la diferencia en el promedio de notas del examen de lengua para los estudiantes que eligen ingeniería y para los que eligen humanidades. Construye un intervalo de confianza para la diferencia en el promedio de notas del examen de matemáticas para los estudiantes que eligen ingeniería y para los que eligen humanidades.
- (b) (1 punto) ¿Qué podemos afirmar a la vista de los resultados obtenidos en el apartado anterior?

Solución:

a) Si asumimos que $\sigma_1 = \sigma_2$:

para tener un intervalo de confianza del 95% en la diferencia de las medias de las notas de **lengua**, tenemos $s_p^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1+n_2-2} = \frac{14(42)^2 + 14(45)^2}{28} = 1894,5$, por lo que el intervalo es

$$446 - 534 \pm 2,048 \sqrt{1894,5 \left(\frac{1}{15} + \frac{1}{15} \right)} = -88 \pm 32,55 = (-120,55, -55,45).$$

Para tener un intervalo de confianza del 95% en la diferencia de las medias de las notas de **matemáticas**, tenemos $s_p^2 = \frac{14(57)^2 + 14(52)^2}{28} = 2976,5$, por lo que el intervalo es

$$548 - 517 \pm 2,048 \sqrt{2976,5 \left(\frac{1}{15} + \frac{1}{15} \right)} = 31 \pm 40,80 = (-9,80, 71,80).$$

Si asumimos que $\sigma_1 \neq \sigma_2$:

para tener un intervalo de confianza del 95 % en la diferencia de las medias de las notas de **lengua**, tenemos $A = \frac{s_1^2}{n_1} = \frac{42^2}{15} = 117,6$ y $B = \frac{45^2}{15} = 135$ y

$\Delta = \text{Entero más próximo} \left[\frac{((n_2-1)A - (n_1-1)B)^2}{(n_2-1)A^2 + (n_1-1)B^2} \right] = \text{Entero más próximo} \left[\frac{(14A - 14B)^2}{14A^2 + 14B^2} \right] =$
Entero más próximo $[0,1322] = 0$, por lo que el intervalo es

$$446 - 534 \pm 2,048 \sqrt{\frac{42^2}{15} + \frac{45^2}{15}} = -88 \pm 32,55 = (-120,55, -55,45).$$

Para tener un intervalo de confianza del 95 % en la diferencia de las medias de las notas de **matemáticas**, tenemos $A = \frac{s_1^2}{n_1} = \frac{57^2}{15} = 216,6$ y $B = \frac{52^2}{15} = 180,27$ y

$\Delta = \text{Entero más próximo} \left[\frac{((n_2-1)A - (n_1-1)B)^2}{(n_2-1)A^2 + (n_1-1)B^2} \right] = \text{Entero más próximo} \left[\frac{(14A - 14B)^2}{14A^2 + 14B^2} \right] =$
Entero más próximo $[0,2327] = 0$, por lo que el intervalo es

$$446 - 534 \pm 2,048 \sqrt{\frac{57^2}{15} + \frac{52^2}{15}} = -88 \pm 40,80 = (-120,80, -39,20).$$

b) Si asumimos que $\sigma_1 = \sigma_2$:

Con una confianza del 95 %, parece haber una diferencia significativa entre las notas de lengua de los dos grupos porque el rango está en valores negativos. Sin embargo, no se observa una diferencia significativa en las notas de matemáticas ya que hay una parte del rango en valores negativos y otra en valores positivos.

Si asumimos que $\sigma_1 \neq \sigma_2$:

Con una confianza del 95 %, en el caso de lengua no cambia el intervalo, por lo que se mantiene una diferencia significativa entre las notas de lengua de los dos grupos porque el rango está en valores negativos. Sin embargo, para matemáticas cambia el intervalo y sí hay una diferencia significativa porque el rango está en valores positivos.

2. (2,5 puntos)

Se sabe que la proporción de líneas de código con errores en un software elaborado por cierta empresa está, con mucha probabilidad, entre el 1 % y el 10 %, y ese conocimiento se puede representar adecuadamente por una distribución Beta con parámetros $r_0 = 1$ y $n_0 = 20$. Se estudia una muestra aleatoria de 1000 líneas de código de un software elaborado por dicha empresa y se encuentran 15 líneas con errores (el programa consiste en varios miles de líneas de código).

- (a) (1,6 puntos) Encontrar la distribución a posteriori para la proporción de líneas de código con errores en ese software; especificar explícitamente esa distribución, de la forma: “La distribución a posteriori de la variable aleatoria ... es ...”.
- (b) (0,3 puntos) En base a la distribución a posteriori, ¿cuál sería la proporción de líneas de código con errores más probable (es decir, la “proporción a posteriori”)?
- (c) (0,3 puntos) En base a la distribución a posteriori, ¿cuál es el valor esperado de la proporción de líneas de código con errores?
- (d) (0,3 puntos) Se recoge una muestra aleatoria adicional de 300 líneas de código y en ella no se observa ninguna línea con errores. Indicar, de forma explícita, como en el apartado a), la distribución a posteriori actualizada (es decir, posterior a la observación de las dos muestras, tanto de la primera de 1000 líneas como de la segunda de 300 líneas).

Solución:

a)

Lo que buscamos es la distribución a posteriori para la proporción poblacional, p . Bajo el enfoque bayesiano, p es una variable aleatoria y su distribución a priori, en este caso, es $f(p) \sim \text{Beta}(r_0 = 1, n_0 = 20)$.

Se obtiene una muestra $\mathbf{x}$ de $n_m = 1000$ líneas de código y se encuentran $r_m = 15$ líneas con errores. Utilizando la propiedad conjugada de la distribución Beta, la distribución a posteriori de p es

$$f(p | \mathbf{x}) \sim \text{Beta}(r = r_0 + r_m, n = n_0 + n_m) = \text{Beta}(r = 1 + 15, n = 20 + 1000) = \text{Beta}(r = 16, n = 1020).$$

Esto significa que, dada la creencia a priori y los datos de la muestra, la creencia actualizada sobre la proporción de líneas de código con errores sigue una distribución Beta con parámetros $r = 16$ y $n = 1020$ (o, lo que es lo mismo, una distribución Beta con parámetros $\alpha = 16$ y $\beta = 1005$).

Es decir, la distribución a posteriori de la variable aleatoria p es una distribución Beta con parámetros $r = 16$ y $n = 1020$.

Encuentra tu camino con la brújula UNIE

unie*
Universidad

Probabilidades y Estadística II: Examen miércoles 12 junio 2024 Soluciones — Examen final

b)

La fórmula para el valor más probable, es decir, la moda, de la distribución Beta es $\frac{r}{n}$. Por tanto, la proporción de líneas de código con errores más probable es $\frac{16}{1020} \approx 0,016 = 1,6\%$.

c)

La fórmula para el valor esperado de la distribución Beta es $\frac{r+1}{n+2}$. Por tanto, el valor esperado de la proporción de líneas de código con errores es $\frac{17}{1022} \approx 0,017 = 1,7\%$.

d)

Se obtiene una muestra $\mathbf{y}$ de $n_{m1} = 300$ líneas de código y se encuentran $r_{m1} = 0$ líneas con errores. Tomando la distribución a posteriori del paso anterior, $f(p | \mathbf{x})$, como la nueva distribución a priori, y utilizando la propiedad conjugada de la distribución Beta, la nueva distribución a posteriori de p es

$$f(p | \mathbf{x}, \mathbf{y}) \sim \text{Beta}(r + r_{m1}, n + n_{m1}) = \text{Beta}(16 + 0, 1020 + 300) = \text{Beta}(16, 1320).$$

3. (2,5 puntos)

Consideramos la cantidad de hidratos de carbono en 100 gramos de pan que produce un obrador artesanal. Dadas dos muestras aleatorias simples e independientes:

X_B y X_I recogen las medidas de hidratos de carbono del pan blanco e integral, respectivamente.

$X_B : 56,90, 54,34, 51,46, 50,93, 57,79, 58,46, 54,67, 51,36$

$X_I : 42,87, 43,39, 40,64, 51,34, 53,16, 50,46$

1. $\sum_{i \in 1:8} X_{B,i} = 435,9395, \sum_{i \in 1:6} X_{I,i} = 281,8799,$

2. $\sum_{i \in 1:8} X_{B,i}^2 = 23819,57, \sum_{i \in 1:6} X_{I,i}^2 = 13382,01$

Suponer que la varianza de las medidas de hidratos de carbono del pan es 25 gramos² y en la inferencia admitir una significación de $\alpha = 0,2$.

(a) Contrastar la hipótesis de que la media de X_B , μ_B , y la media de X_I , μ_I , son iguales, es decir: $H_0 : \mu_B - \mu_I = 0$

(b) ¿Qué decisión se toma al realizar el contraste de hipótesis que propone $H_0 : \mu_B - \mu_I = 2 * (\bar{X}_B - \bar{X}_I)$?

Un test rápido para
saber qué estudiar
después del bachillerato.



Hacer el test

WUOLAH

Solución:

Formulamos el contraste paramétrico:

1. $H_0 : \mu_B - \mu_I = 0$
2. $H_1 : \mu_B - \mu_I \neq 0$

Calculamos

1. $\bar{X}_B = 1/n_B \sum X_{B,i} = 54,49244$
2. $\bar{X}_I = 1/n_I \sum X_{I,i} = 46,97998$

De la Tabla de la distribución Normal estándar tomamos el cuantil

$$z_{\alpha/2} = \phi(1 - \alpha/2) = \phi(0,9) = 1,28$$

- (a) La medida de discrepancia es $d = \frac{\bar{X}_B - \bar{X}_I - (\mu_B - \mu_I)}{\sqrt{\sigma_B^2/n_B + \sigma_I^2/n_I}}$, en poblaciones normales, con varianzas conocidas y H_0 cierta, $d = \frac{7,512457}{2,700309}$, donde $d = 2,782073$

La región de no rechazo es $(-z_{\alpha/2=0,1}, z_{\alpha/2=0,1}) = (-1,28, 1,28)$, $|d| \in (-1,28, 1,28)$

La decisión a tomar no es aceptar H_0

- (b) $H_0 : \mu_B - \mu_I = 0$ ha sido rechazada en el apartado anterior

$\bar{X}_B - \bar{X}_I = 7,512457$, el contraste que se plantea es $H_0 : \mu_B - \mu_I = 2 * 7,512457 = 15,02491$

No es necesario realizar el contraste: la discrepancia d tiene igual valor absoluto y la región de no rechazo es la misma. Si un contraste bilateral no acepta H_0 para un valor a , no aceptamos H_0 para el valor simétrico respecto al centro del intervalo, $2 * (\bar{X}_B - \bar{X}_I) - a$.

Y se prueba:

$$d = \frac{-7,512457}{2,700309} = -2,782073, \text{ con igual región de no rechazo}$$

$$|d| \in (-1,28, 1,28)$$

La decisión a tomar no es aceptar H_0

Encuentra tu camino con la brújula UNIE



Hacer el test

Un test rápido para
saber qué estudiar
después del bachillerato.

unie*
Universidad

4. (2,5 puntos)

Una empresa de venta de combustible ha medido el contenido de resinas de una de sus gasolinas tomando una muestra aleatoria de sus gasolinas, obteniendo los siguientes valores:

4.36 4.43 4.25 4.53 3.82 3.54 3.89 3.45 4.19 3.9 4.55 3.97

Contraste que la variable *cantidad de resinas en la gasolina* sigue una distribución normal con una $\alpha = 0,05$.

Se proporciona la siguiente tabla para agilizar los cálculos:

x_h	$F_n(x_h)$	z_h	$F(x_h)$	$ F_n(x_h) - F(x_h) $	$ F_n(x_{h-1}) - F(x_h) $
			0,04578544		
			0,07443042		
			0,2464531		
			0,3098677		
			0,3194781		
			0,3898575		
			0,6239158		
			0,6837399		
			0,7811015		
			0,8328245		
			0,8917811		
			0,9015076		

Nota: los valores de la columna $F(x_h)$ se han obtenido con $pnorm(z_h)$, siendo z la variable tipificada $Z = \frac{X-\mu}{\sigma} \sim N(0,1)$.

Solución:

Como el número de datos es menor que 30 usamos el contraste KS (Kolmogorov-Smirnov).

Sabemos que la distribución es normal, y podemos calcular $\hat{\mu} = \bar{x} = 4,073$ y $\hat{\sigma} = \sqrt{\frac{\sum x_i^2 - n\bar{x}^2}{n-1}} = 0,369455$.

Por tanto, la hipótesis nula es $X \sim N(4,073, 0,369455)$

Si obtenemos la variable tipificada $Z = \frac{X-\mu}{\sigma} \sim N(0,1)$ podemos rellenar la tabla:

- 1) ordenamos los valores de menor a mayor.
- 2) calculamos

$$n = 12$$

$$F_n(x) = k/n \text{ si } x_k < x < x_{k+1}; k = 1, 2, 3 \dots 12$$

Encuentra tu camino con la brújula UNIE

x_h	$F_n(x_h)$	z_h	$F(x_h)$	$ F_n(x_h) - F(x_h) $	$ F_n(x_{h-1}) - F(x_h) $
3,45	0,08333333	-1,6871689	0,04578544	0,03754789	0,04578544
3,54	0,16666667	-1,4435669	0,07443042	0,09223625	0,00890291
3,82	0,25	-0,6856938	0,2464531	0,0035469	0,07978643
3,89	0,33333333	-0,4962255	0,3098677	0,02346563	0,0598677
3,9	0,41666667	-0,4691586	0,3194781	0,09718857	0,01385523
3,97	0,5	-0,2796904	0,3898575	0,1101425	0,02680917
4,19	0,58333333	0,31578135	0,6239158	0,04058247	0,1239158
4,25	0,66666667	0,47818273	0,6837399	0,01707323	0,10040657
4,36	0,75	0,77591858	0,7811015	0,0311015	0,11443483
4,43	0,83333333	0,96538685	0,8328245	0,00050883	0,0828245
4,53	0,91666667	1,23605581	0,8917811	0,02488557	0,05844777
4,55	1	1,2901896	0,9015076	0,0984924	0,01515907

En negrita están $\max\{|F_n(x_h) - F(x_h)|\}$ y $\max\{|F_n(x_{h-1}) - F(x_h)|\}$, de donde $D_{12} = 0,12392$. En la tabla KS vemos que $D_{12} = 0,12392 < D_{12,0,05} = 0,3754$, por lo que **no podemos rechazar la hipótesis** de que sigue una distribución $N(4.073, 0.369455)$ con un nivel de significación del 5 % ($\alpha = 0,05$).

Un test rápido para
saber qué estudiar
después del bachillerato.



Hacer el test

