

Lección 2, Probabilidades y Estadística II

Lección 2, semana 2, 19/02/2026

Juan A Fdez del Pozo (CIG-UPM)

February 24, 2026

Probabilidades y Estadística II

Inferencia Estadística

- Guía de Aprendizaje
- Datos generales, Competencias,

Resultados, Temario, Cronograma,
Evaluación, Recursos

Temario de la asignatura

1. Unidad Didáctica 1: Estimación del Modelo
 - 1.1. Tema 1: Introducción a la Inferencia
 - 1.2. Tema 2: Estimación puntual
 - 1.3. Tema 3: Estimación por intervalos
 - 1.4. Tema 4: Estimación Bayesiana
2. Unidad Didáctica 2: Contrastes de hipótesis
 - 2.1. Tema 5: Contrastes paramétricos
 - 2.2. Tema 6: Contrastes no paramétricos
3. Unidad Didáctica 3: Regresión lineal simple
 - 3.1. Tema 7: Regresión lineal simple

Práctica

Presentación y Objetivos

- Comprender el concepto de estimador y su distribución
- Conocer y saber aplicar el método de los momentos y el de máxima verosimilitud para obtener estimadores

Esquema Inicial

- Introducción
- Estadísticos y estimadores
- Métodos de obtención de estimadores
- Obtención de estimadores en la distribución Normal.
- Distribuciones asociadas a la Normal y Teorema de Fisher

Probabilidades y Estadística II, Tema 2

Estimación puntual

Se observa una m.a.s. de una v.a. $X \sim H(\theta)$, hipótesis.

Se sabe la forma de H pero se ignora el valor de sus parámetros.

¿cómo se puede utilizar los datos/información muestral para aproximar los parámetros desconocidos?

Estimación puntual // por intervalos

Proponer valores concretos a los parámetros desconocidos

- Estimación puntual:
se da un *único valor aproximado* para el parámetro desconocido, un solo punto o número real
- Estimación por intervalos:
se da un *intervalo de valores posibles* para el parámetro desconocido.
En ese intervalo se cree que se encuentra el verdadero valor del parámetro con cierta *seguridad que habrá que especificar*

Parámetro de una distribución

Es un valor utilizado para representar una característica concreta de la distribución de una variable aleatoria X .

En inferencia estadística esta variable aleatoria representará a la población bajo estudio.

Ejemplos

- Si $X \sim N(\mu, \sigma)$,
 μ será el parámetro que representa la media poblacional y
 σ será el parámetro que representa la desviación típica
- Si $X \sim P(\lambda)$,
 λ representa la media poblacional
- $X \sim \text{Exp}(\lambda)$,
el parámetro λ representa la tasa de la distribución

Probabilidades y Estadística II, Tema 2

Estimación puntual

Dada $\{X_1, X_2, \dots, X_n\}$ m.a.s. de una v.a. X , se llama estadístico a toda función (medible) de los elementos de la muestra, es decir,

$$\text{Estadístico} = T(X_1, X_2, \dots, X_n)$$

Un estimador de un parámetro

- Estadístico cuya finalidad es aproximar el verdadero valor del parámetro desconocido
- Para estimar un parámetro genérico θ se utilizará la notación $\hat{\theta}$ para designar su estimador
- Los estadísticos son variables aleatorias y son funciones que **no** dependen del parámetro desconocido
- Se observa la muestra $\{X_1 = x_1, X_2 = x_2, \dots, X_n = x_n\}$ y el estadístico resume la información contenida en la muestra para dar información sobre θ

Probabilidades y Estadística II, Tema 2

Estimación puntual

Sea $\{X_1, X_2, \dots, X_n\}$ m.a.s. de una v.a.

Ejemplo

- Si $X \sim N(\mu, \sigma)$ un estadístico sería
- $T(X_1, X_2, \dots, X_n) = \sum X_i^2$, un estadístico
- $T(X_1, X_2, \dots, X_n) = \mu \sum X_i^2$, **no** un estadístico
- Si $X \sim N(\mu, 1)$
- Se pueden tomar como estimadores del parámetro μ : $\hat{\mu} = \bar{X}$, $\hat{\mu} = \text{Med}(X)$, al ser la distribución normal simétrica, la media y la mediana coinciden

Ejemplo

- Si $X = \text{número de trabajos enviados a una impresora en un día}$ suponiendo que $X \sim P(\lambda)$.
- Si se observa el número de trabajos enviados en n días $\rightarrow$ m.a.s. de X
- Se pueden tomar como estimadores de λ :
 $\hat{\lambda} = \bar{X}$, $\hat{\lambda} = \min(X_i)$, $\hat{\lambda} = \max(X_i)$

Probabilidades y Estadística II, Tema 2

Estimación puntual

Para un mismo parámetro se pueden proponer diferentes estimadores
→ métodos para obtener buenos estimadores.

El método de los momentos y el método de máxima verosimilitud

Método de los momentos

- Se estiman los momentos poblacionales por los correspondientes muestrales.
- Encontrar relaciones funcionales, tantas como parámetros se quieren estimar, entre los momentos con respecto del origen de la variable aleatoria de la que proviene la muestra y los parámetros
- Estimar los momentos poblacionales, $\{\alpha_i\}_1^k$, por medio de los momentos muestrales, $\{a_i\}_1^k$, obteniendo los estimadores
- Momentos poblacionales respecto del origen:
→ $\alpha_k = \int x^k * f(x)dx$; → $\alpha_k = \sum x_i^k * P(x_i)$ (formularios de v.a.)
- Momentos muestrales respecto del origen:
Sea $\{X_1, X_2, \dots, X_n\}$ m.a.s. de una v.a.
→ $a_k = 1/n \sum n_i * x_i^k$

Probabilidades y Estadística II, Tema 2

Estimación puntual

El método de los momentos y el método de máxima verosimilitud

Método de los momentos, ejemplo

- Sea $X \sim \gamma(\lambda, p)$ v.a. y $\{X_1, X_2, \dots, X_n\}$ m.a.s. de X
- Obtener estimadores de los parámetros λ y p por el método de los momentos
- Primero se buscan relaciones funcionales entre los momentos respecto del origen de X y los parámetros a estimar (formulario)
- $E(X) = \alpha_1 = \frac{p}{\lambda}$
- $E(X^2) = \alpha_2 = \text{Var}(X) + E(X)^2 = \frac{p}{\lambda^2} + (\frac{p}{\lambda})^2$
- $\lambda = \lambda(\alpha_1, \alpha_2)$, $p = p(\alpha_1, \alpha_2)$, despejar en las fórmulas
- $\lambda = \frac{\alpha_1}{\alpha_2 - \alpha_1^2}$; $p = \frac{\alpha_1^2}{\alpha_2 - \alpha_1^2}$ (parámetros poblacionales desconocidos)
- $\hat{\lambda} = \hat{\lambda}(a_1, a_2)$, $\hat{p} = \hat{p}(a_1, a_2)$, donde
- $a_1 = \frac{\sum x_i}{n} = \bar{X}$, $a_2 = \frac{\sum x_i^2}{n} \rightarrow \rightarrow \rightarrow \hat{\lambda} = \frac{a_1}{a_2 - a_1^2}$; $\hat{p} = \frac{a_1^2}{a_2 - a_1^2}$ (estimaciones)

Estimar puntualmente los parámetros λ y p , con la m.a.s. $\{0.16053 \ 0.32699 \ 0.61982 \ 0.27486 \ 0.33548 \ 0.08470\}$,

(`rgamma(6, rate=10, shape=4)`, $\lambda \sim 10$ y $p \sim 4$), $\hat{\lambda} = 10.56$, $\hat{p} = 3.17$

Probabilidades y Estadística II, Tema 2

Estimación puntual

Dada $X \sim N(\mu, \sigma)$,

encontrar los estimadores para los parámetros μ y σ por el

Método de los momentos

- Estimar el parámetro bidimensional $\theta = (\mu, \sigma)$
- $E(X) = \alpha_1 = \mu$, $E(X^2) = \alpha_2 = \sigma^2 + \mu^2$
- $\hat{\mu} = a_1 = \bar{X} = \frac{\sum x_i}{n}$
- $\hat{\sigma}^2 = a_2 - \bar{X}^2 = \frac{\sum (x_i - \bar{X})^2}{n}$ (sesgo?)

Estimar puntualmente los parámetros μ y σ , con la m.a.s. {1.327768 2.120262 2.041221 1.420598 2.517780 2.040761 2.024980},

(`rnorm(7, mean=2.0, sd=0.4)`, $\mu \sim 2$ y $\sigma \sim 0.4$), $\hat{\mu} = 1.93$, $\hat{\sigma} = 0.37$,

Los sistemas de ecuaciones pueden ser complicados de despejar y se procede numericamente

Función de verosimilitud y Método

Método de máxima verosimilitud

Dada $\{X_1, X_2, \dots, X_n\}$ m.a.s. discreta de v.a. X con f. de probabilidad, $P_\theta(X)$.

- Función de verosimilitud.

Función de probabilidad conjunta de la muestra

$$P_\theta(X_1 = x_1, \dots, X_n = x_n) = \prod P_\theta(x_i)$$

Función de al m.a.s. y del parámetros

- Si θ fuera conocido, esta función determina la probabilidad de obtención de cada muestra
- Si θ es desconocido y se conoce un valor concreto y fijo de la muestra $(x_1, \dots, x_n)$, esta función daría, para cada valor de θ , la probabilidad de obtener esa muestra observada

La función de probabilidad o de densidad conjunta de la m.a.s. $\{X_1, X_2, \dots, X_n\}$, vista como función de θ , se denomina función de verosimilitud $L(\theta)$

Método de máxima verosimilitud, *MLE*

Función de verosimilitud y Método

- Método.

$L(\theta) = \prod P_{\theta}(x_i)$ v.a. discreto // $L(\theta) = \prod f_{\theta}(x_i)$ v.a. continua

- El *MLE* selecciona como estimador del parámetro desconocido θ , aquel valor que maximiza la probabilidad de la muestra aleatoria observada

$$\hat{\theta} = \max \arg_{\theta} L(\theta)$$

- Sea L función de verosimilitud diferenciable, cuyo máximo no se alcanza en un extremo de su recorrido
- El parámetro θ es k -dimensional, $\theta = (\theta_1, \dots, \theta_n)$
- θ es el valor estacionario del máximo de L , $\{\frac{\partial L(\theta)}{\partial \theta_i} = 0, \forall i\}$, y matriz Hessiana es definida negativa

→ $\ln(L(\theta)) \sim$ Función soporte, $\ln$ de la función de verosimilitud

Probabilidades y Estadística II, Tema 2

Estimación puntual

Ejemplo

Se toma una m.a.s. $\{X_1, X_2, \dots, X_n\}$. Encontrar el MLE del parámetro λ .

- Supóngase que $X \sim P(\lambda)$.
- Lo primero construir la función de verosimilitud
- $$L(\lambda) = \prod_{i=1}^n P_\lambda(x_i) = \prod_{i=1}^n e^{-\lambda} \frac{\lambda^{x_i}}{x_i!} = e^{-n\lambda} \frac{\lambda^{\sum_{i=1}^n x_i}}{\prod_{i=1}^n x_i!}$$
- Calculamos el $\ln(L(\lambda)) =$
- $-n\lambda + \sum_{i=1}^n x_i \ln(\lambda) - \ln(\prod_{i=1}^n x_i!)$
- Calculamos el máximo, los ceros de $\frac{\partial \ln(L(\lambda))}{\partial \lambda} = 0$
- $-n + \frac{\sum_{i=1}^n x_i}{\lambda} = 0 \rightarrow \hat{\lambda} = \frac{\sum_{i=1}^n x_i}{n} = \bar{X}$
- Comprobamos la condición de máximo: $\frac{\partial^2 \ln(L(\lambda))}{\partial^2 \lambda} = -\frac{\sum_{i=1}^n x_i}{\lambda^2} = -1/\bar{X} < 0$

La expresión es menor que cero ya que los elementos de una m.a.s. que proviene de una distribución de *Poisson* son todos positivos y, por tanto, su media es positiva

Distribuciones asociadas a la Normal

- χ^2 de Pearson

Sean las $Z_1, \dots, Z_n$ v.a.i.i.d $\sim N(0, 1)$,

y sea $X = \sum_{i=1}^n Z_i^2$, decimos que $X \sim \chi_n^2$, n grados de libertad

Caso particular de la distribución $\gamma(\lambda = 1/2, p = n/2)$,

$E(X) = n$, $Var(X) = 2n$,

Si $X \sim \chi_{n_1}^2$ y $Y \sim \chi_{n_2}^2 \rightarrow X + Y \sim \chi_{n_1+n_2}^2$

- t de Student
- F Fisher-Snedecor

Gráficas de densidad, Tablas y funciones de R.

Distribuciones asociadas a la Normal

- χ^2 de Pearson

- **t de Student**

Definimos $T = \frac{Z}{(X/n)^{1/2}} \sim t_n$,

n grados de libertad, donde $Z \sim N(0, 1)$ y $X \sim \chi_n^2$

$$E(T) = 0, \text{ Var}(T) = \frac{n}{n-2}, n > 2$$

- F Fisher-Snedecor

Gráficas de densidad, Tablas y funciones de R.

Distribuciones asociadas a la Normal

- χ^2 de Pearson

- t de Student

- **F Fisher-Snedecor**

Si $X \sim \chi_m^2$ y $Y \sim \chi_n^2$, definimos $F = \frac{X/m}{Y/n} \sim F_{m,n}$,

$$E(F) = \frac{m}{m-2}, m > 2, \text{Var}(F) = \frac{m^2 * (2n+2m-4)}{n * (m-2)^2 * (m-4)^2}, m > 4$$

Gráficas de densidad, Tablas y funciones de R.

Teorema de Fisher

El Teorema de Fisher nos dice que:

Si $\{X_1, X_2, \dots, X_n\}$ es una m.a.s. de $X \sim N(\mu, \sigma)$, se verifica que

- las v.a. $\bar{X}$ y S^2 , media muestral y cuasivarianza muestral, son independientes
- la v.a.

$$\frac{\bar{X} - \mu}{\sigma/n^{1/2}} \sim N(0, 1)$$

- la v.a.

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

Probabilidades y Estadística II, Tema 2

Estimación puntual

Propiedades de los estimadores

Estimadores

- Para un parámetro puede haber varios estimadores.
- En ese caso elegiremos el estimador que tenga la mejor de alguna de las propiedades de los estimadores:

Propiedades

sesgo, eficiencia, consistencia, convergencia, robustez, . . .

Por ejemplo, el estimador $\hat{S}^2$ es mejor que el estimador $\hat{\sigma}^2$ porque no tiene sesgo.

Población $\rightarrow$ Parámetro $\rightarrow$ Estimadores

- $\rightarrow$ Población $N(\mu, \sigma)$
- $\rightarrow \rightarrow$ Parámetro σ
- $\rightarrow \rightarrow \rightarrow$ Estimadores $\hat{\sigma}^2$ o $\hat{S}^2$

Propiedades de los estimadores

Sesgo.

- Sea una distribución de parámetro θ (por ejemplo, una distribución normal de parámetro μ).
- Un estimador $T(X)$ se dice que es un estimador no sesgado (unbiased de θ) si:
 - $\equiv E_{\theta}(T(X)) = \theta$ El subíndice θ indica que el valor esperado E se calcula con respecto a la distribución que tiene parámetro θ
 - $Sesgo_{\theta} = E_{\theta}(T(X)) - \theta$
Estimado insesgado $\rightarrow Sesgo = 0$.

$$Var_{\theta}(T(X)) = E_{\theta}((T(X) - E_{\theta}(T(X)))^2)$$

El sesgo y la varianza caracterizan las propiedades del estimador, ambos deben ser pequeños en un estimador aceptable

Propiedades de los estimadores

Eficiencia.

- Sea una distribución de parámetro θ (por ejemplo, una distribución normal de parámetro μ)
- Un estimador no sesgado $T_1(X)$ se dice más eficiente que otro estimador no sesgado $T_2(X)$ si:

$$Var_{\theta}(T_1(X)) \leq Var_{\theta}(T_2(X)), \forall \theta \in \Theta$$

y

$$\exists \theta \in \Theta \rightarrow Var_{\theta}(T_1(X)) < Var_{\theta}(T_2(X))$$


- Para estimadores no sesgados su varianza es el error cuadrático medio ECM (MSE)

$$ECM_{\theta}(T(X)) = E_{\theta}((T(X) - \theta)^2) = Var_{\theta}(T(X)) + (Sesgo(T(X)))^2$$

Propiedades de los estimadores

Sesgo y Varianza

- Sin sesgo y baja varianza
- Con sesgo y baja varianza



- Sin sesgo y alta varianza
- Con sesgo y alta varianza

Propiedades de los estimadores

Consistencia

- En un buen estimador, a medida que aumenta el tamaño de la muestra, el valor del estimador se acercará al parámetro estimado
- Sea $T_1, \dots, T_n$ una secuencia de estimadores del parámetro θ , donde $T_n = T_n(X_1, \dots, X_n)$ es una función de $\{X_1, \dots, X_n\}$
- La secuencia T_n es consistente en la estimación de θ si $\forall \epsilon > 0$

$$\lim_{n \rightarrow \infty} P(|T_n - \theta| < \epsilon) = 1$$

- $\bar{X}_n$ es un estimador consistente de μ (la media poblacional)
- Este concepto de consistencia es llamado débil
- Un estimador es consistente *ECM* si el $ECM \rightarrow 0$ cuando $n \rightarrow \infty$
- Si $T(X)_n$ es consistente *ECM* también es débil
- La varianza de $(T(X)_n) = \bar{X}_n$ es $\frac{\sigma^2}{n}$, que tiende a 0 cuando n tiende ∞
- $\bar{X}_n$ es consistente débil y *EMC*

ESTIMACIÓN DE MÁXIMA VEROSIMILITUD

Un marco general para la estimación de parámetros.

- Ejemplo con la distribución de Bernoulli
- Sea la m.a.s. $\{X_1, \dots, X_n\}$ de una población de Bernoulli, v.a. binaria $p = P(X = 1), 1 - p = P(X = 0)$
- Para una muestra concreta:
$$P(X_1 = x_1, \dots, X_n = x_n | p) =$$
$$P(X_1 = x_1 | p) * P(X_2 = x_2 | p) * \dots * P(X_n = x_n | p) =$$
$$\prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i}$$
- En general a esta función, dada la distribución y dependiente de los parámetros a estimar, se la llama función de verosimilitud:

$$L(x_1, \dots, x_n | p) = \prod_{i=1}^n p^{x_i} (1 - p)^{1-x_i}$$

- Ejemplo: $L(\{1, 1, 0, 1, 0\} | p) = pp(1 - p)p(1 - p) = p^3(1 - p)^2$

ESTIMACIÓN DE MÁXIMA VEROSIMILITUD

Un marco general para la estimación de parámetros

- El principio de estimación de máxima verosimilitud establece que el estimador de p , $\hat{p}$, es el valor de p que maximiza la función L , verosimilitud
- La estimación maximoverosímil de un parámetro maximiza la probabilidad de los datos observados en el m.a.s.
- Se trabaja con $l = \ln(L)$, la función soporte, pues el cálculo del máximo se simplifica en el proceso de derivar la función
- $l(11010|p) = \ln(p^3(1-p)^2)$, el máximo se alcanza en un punto estacionario $l' = d(l)/dp = 0$ si $l'' = d^2(l)/d^2p < 0$
- $d(l)/dp = \frac{d(p^3(1-p)^2)}{dp} = 3\ln(p) + 2\ln(1-p)$, $3/p - 2/(1-p) = 0$,
- $\hat{p} = 1/5 = 1/5 * (1 + 1 + 0 + 1 + 0)$,
 $l'' = -3/p^2 + 2/(1-p)^2 = -3 * 25 + 2 * 25/16 < 0$

¿Comentarios y Preguntas?

GII-PYEII 2026

05/02/2026, CIG: www.cig.fi.upm.es