

# Lección 4, Probabilidades y Estadística II

Lección 4, semana 7, 19/03/2026

Juan A Fdez del Pozo (CIG-UPM)

March 12, 2026

# Probabilidades y Estadística II

## Inferencia Estadística

- Guía de Aprendizaje
- Datos generales, Competencias,

Resultados, Temario, Cronograma,  
Evaluación, Recursos

### Temario de la asignatura

1. Unidad Didáctica 1: Estimación del Modelo
  - 1.1. Tema 1: Introducción a la Inferencia
  - 1.2. Tema 2: Estimación puntual
  - 1.3. Tema 3: Estimación por intervalos
  - 1.4. Tema 4: Estimación Bayesiana
2. Unidad Didáctica 2: Contrastes de hipótesis
  - 2.1. Tema 5: Contrastes paramétricos
  - 2.2. Tema 6: Contrastes no paramétricos
3. Unidad Didáctica 3: Regresión lineal simple
  - 3.1. Tema 7: Regresión lineal simple

### Práctica

### Contenidos

- Introducción
- Distribuciones a priori
- Estimación puntual
- Estimación de una proporción
- Estimación de la media en poblaciones normales
- Comparación con los métodos clásicos
- Software
- Ejercicios

### Introducción

- Los métodos de estimación que hemos presentado en los temas anteriores funcionan muy bien con muestras grandes, pero con muestras pequeñas o medianas no proporcionan siempre respuestas satisfactorias.
- Consideremos, **primer ejemplo**, que tratamos de estimar la proporción de estudiantes de una universidad que han leído la novela Rayuela de Julio Cortázar.
- Supongamos que se pregunta a una muestra aleatoria de 30 estudiantes y el resultado es que ninguno de los miembros de la muestra ha leído esta novela. ¿Qué inferencia podemos hacer?
- Si aplicamos el estimador máximo-verosímil ( $MV$ ) del parámetro de una población binomial es la frecuencia en la muestra, que, en este caso, es cero.
- La estimación del número de estudiantes que han leído esta novela es cero.
- Para cuantificar la precisión de esta estimación nos encontramos que la varianza estimada es cero, o la precisión infinita. ¿Es esto razonable?

### Introducción

- Claramente no.
- El problema es que estamos aplicando un método de  $MV$ , que tiene buenas propiedades en muestras grandes pero puede dar resultados poco satisfactorios en pequeñas o incluso medianas muestras.
- Como **segundo ejemplo** supongamos que tratamos de estimar la edad del más veterano de los estudiantes de una universidad mediante esa misma muestra de tamaño 30.
- Como desconocemos la distribución de edades, podríamos, por analogía, estimar como valor máximo de la variable edad el mayor valor observado en la muestra.
- Supongamos que la persona de mayor edad es de 21 años.
- Esta estimación es intuitivamente muy deficiente: si hay una pequeña proporción de personas mayores en la universidad, probablemente no serán seleccionadas en una muestra pequeña, y el error cometido puede ser muy grande.

### Introducción

- Como **tercer ejemplo** supongamos que sacamos al azar una moneda del bolsillo, la tiramos 10 veces y obtenemos 7 caras y 3 cruces.  
¿Quiere esto decir que debemos admitir que la probabilidad de cara en esta moneda es 0.7?
- → ¿Qué tienen en común los tres ejemplos anteriores?
- →→ la existencia de cierta información a priori respecto al parámetro que tratamos de estimar, que no se tiene en cuenta en el proceso de inferencia.
- Ignorar la información inicial, que llamaremos **información a priori**, que tenemos respecto a un parámetro a estimar no es importante si la muestra es grande, ya que entonces probablemente queremos despreciar nuestra información a priori frente a los datos, pero puede serlo cuando la información a priori sea significativa frente a los datos.

### Introducción


- La inferencia Bayesiana es un procedimiento general para combinar nuestra **información a priori** con la muestra para obtener una inferencia que tenga en cuenta toda la información existente en el problema.
- En el enfoque Bayesiano un **parámetro** no es una constante desconocida, sino una variable aleatoria sobre la que podemos establecer a priori una distribución de probabilidad que refleje nuestro conocimiento del problema.
- La inferencia respecto a sus posibles valores se obtiene aplicando el cálculo de probabilidades (**teorema de Bayes**) para combinar la información inicial con la muestral y obtener la distribución del parámetro condicionada a la información disponible.

# Probabilidades y Estadística II, Tema 4

## Estimación Bayesiana

### Introducción

- Probabilidad condicionada  $\rightarrow$  Sean  $A$  y  $B$  dos eventos tal que  $P(A) > 0$ . Denotamos  $P(B|A)$  a la probabilidad de  $B$  dado que  $A$  ha ocurrido.
- Definición:  $P(B|A) = \frac{P(A \cap B)}{P(A)} \rightarrow P(A \cap B) = P(A) \cdot P(B|A)$



- “la probabilidad de que ocurran tanto  $A$  como  $B$  es igual a la posibilidad de que ocurra  $A$ , por la probabilidad de que ocurra  $B$ , dado que ha ocurrido  $A$ ”

Generalización para  $n$  eventos  $\rightarrow$

Si un suceso  $A$  debe ser el resultado de la ocurrencia de uno de los eventos mutuamente excluyentes  $A_1, A_2, \dots, A_n$ , entonces

$$P(A) = \sum P(A|A_i) \cdot P(A_i)$$



### Introducción

- Eventos independientes  $\rightarrow$   
Si  $P(B|A) = P(B)$ , es decir,  
si la probabilidad de que  $B$  ocurra no se ve afectada por  
la ocurrencia o la no ocurrencia de  $A$ ,  
entonces se dice que  $A$  y  $B$  son eventos independientes.

- Esto es equivalente a

$$P(A \cap B) = P(A) \cdot P(B)$$

(recuerda que habíamos definido  $P(A \cap B) = P(A) \cdot P(B|A)$ )

### Introducción

- Teorema de Bayes →

Si  $A_1, A_2, \dots, A_n$  son eventos mutuamente excluyentes cuya unión es el espacio muestral, esto es, uno de estos eventos debe ocurrir.

Entonces, si  $A$  es un evento cualquiera, se tiene que:

$$P(A_k|A) = \frac{P(A|A_k) \cdot P(A_k)}{\sum_j P(A|A_j) \cdot P(A_j)}$$

- Esto permite encontrar las probabilidades de los diversos eventos  $A_1, A_2, \dots, A_n$ , que hacen que  $A$  ocurra.
- Por esta razón, se suele decir que el teorema de Bayes es un teorema sobre la probabilidad de causas.

### Introducción

#### Ejemplo 1.

Una mujer sospecha que puede estar embarazada.

Para estar segura de su estado compra un test del cual se conoce que tiene una eficacia del 90% en detectar embarazos.

La mujer se realiza el test y obtiene un resultado positivo +.

Pregunta: ¿Cuál es la probabilidad de que dicha mujer esté embarazada?

- $P(E|+) = \frac{P(E,+)}{P(+)} = \frac{P(+|E) \cdot P(E)}{P(+|E) \cdot P(E) + P(+|\bar{E}) \cdot P(\bar{E})}$ ,  $T^{ma}$  de bBayes
- Adicionalmente supongamos que el test da falsos positivos el 50% de las veces y que, sin ninguna información adicional, la probabilidad de concepción después de mantener una relación sexual es del 15%.
- $P(E|+) = \frac{0.90 \cdot 0.15}{0.90 \cdot 0.15 + 0.5 \cdot 0.85} = 0.241 \ (0.241 \ll 0.9)$

### Introducción

- Supongamos que la mujer para confirmar su estado se realiza un nuevo test de embarazo y obtiene nuevamente un resultado positivo +.
- Con esta información adicional, ¿cómo cambian nuestras conclusiones? ¿Cuál es la probabilidad de que la mujer esté embarazada?
- $$P(E|+) = \frac{P(E,+)}{P(+)} = \frac{P(+|E) \cdot P(E)}{P(+|E) \cdot P(E) + P(+|\bar{E}) \cdot P(\bar{E})}$$
- $$P(E|+) = \frac{0.90 \cdot 0.0.241}{0.90 \cdot 0.241 + 0.5 \cdot 0.759} = 0.364$$
- Si se hacen test sucesivos con resultado +, la probabilidad de embarazo sería:  
test 3 = 0.507, test 4 = 0.649, test 5 = 0.769, test 6 = 0.857,  
test 7 = 0.915, test 8 = 0.951, test 9 = 0.972, test 10 = 0.984.
- Análisis secuencial:
  - Probabilidad a priori: 0.15.
  - Observación de datos: resultado positivo + en el test.
  - Probabilidad a posteriori: 0.24.
  - Actualización de las probabilidades al disponer de nueva información: 0.364

### Introducción

- Jugando con monedas (1/3). Probabilidades clásicas →
- Una caja contiene tres monedas, dos no cargadas y una cargada (con la probabilidad de que salga cara igual a  $P(H) = 0.2$ ).
- Se selecciona al azar una moneda de la caja y se lanza tres veces.
- Si se obtienen dos caras y una cruz,
- ¿cuál es la probabilidad del evento  $F$  de que la moneda seleccionada no esté cargada, y
- cuál es la probabilidad del evento  $B$  de que la moneda sí esté cargada?

### Introducción

- Jugando con monedas (2/3). Probabilidades clásicas →
- Sea  $D$  el evento (datos, evidencia, muestra) donde se obtienen dos caras y una cruz en tres lanzamientos.
- La probabilidad condicional  $P(D|F)$  de observar los datos con base en la hipótesis de que se lance una moneda no cargada es una probabilidad binomial

$$f(x) = P(X = x) = \binom{n}{x} p^x q^{n-x} = \frac{n!}{x!(n-x)!} p^x q^{n-x}$$

es decir,  $f(x)$  es la probabilidad de que un evento ocurra exactamente  $x$  en  $n$  ensayos (esto es,  $x$  éxitos y  $n - x$  fracasos)

- La probabilidad condicional  $P(D|B)$  de observar  $D$  (los datos) cuando la moneda está cargada será, por el teorema de Bayes:

### Introducción

- 

$$P(F|D) = \frac{P(D|F) \cdot P(F)}{P(D|F) \cdot P(F) + P(D|B) \cdot P(B)} = \frac{250}{282} \approx 0.89$$

$$\left( \frac{3(0.5)^3(2/3)}{3(0.5)^3(2/3) + 3(0.5)^2(0.8)(1/3)} \right) \text{ Y también } P(B|D) = 1 - P(F|D) = 0.11$$

- Jugando con monedas (3/3). Probabilidades clásicas →
- En el contexto Bayesiano, la probabilidad no condicional  $P(F)$  se denomina probabilidad a priori (antes de recopilar cualesquiera observaciones) de la hipótesis  $F$  de que se lanzó una moneda no cargada.
- La probabilidad condicional  $P(F|D)$  se llama probabilidad a posteriori de la hipótesis  $F$  (después de observar  $D$ ).
- De manera análoga,  $P(B)$  y  $P(B|D)$  son las probabilidades respectivas, a priori y a posteriori, de que se lanzó una moneda cargada.
- Las probabilidades a priori que se usan aquí son probabilidades clásicas.

### Introducción

- Jugando con monedas (1/3). Probabilidades bayesianas →
- Una caja contiene un número desconocido de monedas no cargadas y cargadas (con  $P(H) = 0.2$  para las cargadas).
- Se selecciona una moneda de manera aleatoria de la caja y se lanza tres veces.
- Si se obtienen dos caras y una cruz.
- ¿Cuál es la probabilidad de que la moneda elegida esté cargada?
- En el caso anterior, la probabilidad a priori  $P(F)$  de elegir una moneda no cargada se pudo determinar mediante el análisis combinatorio.
- Puesto que ahora no se conoce la proporción de monedas no cargadas que hay en la caja, no es posible recurrir a  $P(F)$  como una probabilidad clásica sin que se acuda a tomas repetidas independientes de la caja y aproximarlas como frecuencia relativa.
- Por tanto, no es posible aplicar el teorema de Bayes para determinar la probabilidad a posteriori de  $F$ .



### Introducción

- Jugando con monedas (2/3). Probabilidades Bayesianas →
- Sin embargo, los métodos Bayesianos proporcionan una solución a la cuestión anterior:
- proponen, primero, que la probabilidad a priori no conocida  $P(F)$  es una cantidad aleatoria, digamos  $\theta$ , en virtud de  $\theta$  la incertidumbre en cuanto a su valor exacto, y después de razonar que es posible llegar a una de función probabilidad o de densidad  $p(\theta)$  con  $\theta$  que refleja el grado creencia en diversas propuestas acerca de  $P(F)$ .
- Por ejemplo, podemos argumentar que en ausencia de cualquier evidencia contradictoria, antes de que se lance la moneda, es razonable suponer que la caja contiene un número igual de monedas cargadas y no cargadas.

# Probabilidades y Estadística II, Tema 4

## Estimación Bayesiana

### Introducción

- Jugando con monedas (2/3). Probabilidades Bayesianas →
- Debido a que  $P(H) = 0.2$  en el caso de una moneda cargada y  $P(H) = 0.5$  en el de una no cargada, el parámetro no conocido  $\theta$  tendría entonces la probabilidad subjetiva a priori:

| $\theta$    | 0.2 | 0.5 |
|-------------|-----|-----|
| $p(\theta)$ | 1/2 | 1/2 |

- La probabilidad a posteriori (aplicando Bayes) será:

| $\theta$      | 0.2    | 0.5     |
|---------------|--------|---------|
| $p(\theta D)$ | 32/157 | 125/157 |

- $P(\theta = 0.2|D) = \frac{P(D|\theta=0.2) \cdot P(\theta=0.2)}{P(D|\theta=0.2) \cdot P(\theta=0.2) + P(D|\theta=0.5) \cdot P(\theta=0.5)} =$ 
  - $\frac{3(0.2)^2(0.8)(1/2)}{3(0.2)^2(0.8)(1/2) + 3(0.5)^3(1/2)} = \frac{32}{157} \approx 0.20$
  - $P(\theta = 0.5|D) = 1 - P(\theta = 0.2|D) = \frac{125}{157} \approx 0.80$

### Introducción

- **Jugando con monedas (3/3). Probabilidades bayesianas →**
- Las distribuciones a priori que proporcionan igual peso a todos los valores posibles de un parámetro son ejemplos a priori difusos, imprecisos o no informativos, los cuales con frecuencia son recomendables cuando no se dispone de casi ninguna información previa acerca del parámetro.
- Entonces, el términos Bayesianos: Si  $X$  es una variable aleatoria con una función de densidad de probabilidad  $f(x)$  que depende de un parámetro no conocido  $\theta$ .
- Se supone que la incertidumbre en cuanto al valor de  $\theta$  se puede representar mediante una función de probabilidad o densidad  $P(\theta)$  de una variable aleatoria  $\Theta$
- En consecuencia, es posible considerar una función  $f(x)$  como función de probabilidad (o densidad) **condicional** de  $X$  dada  $\Theta = \theta$ , y se denota por  $f(x|\theta)$ .

### Introducción

- Jugando con monedas (3/3). Probabilidades bayesianas →
- La función de probabilidad o densidad conjunta de  $X$  y  $\Theta$  se denota por

$$f(x, \theta)$$

- La función de probabilidad o densidad a posteriori de  $\Theta$  dado  $X = x$  se denota por

$$f(\theta|x)$$

- Si  $x_1, x_2, \dots, x_n$  es una muestra aleatoria de valores de  $X$ , la función de densidad conjunta de la muestra se llama función de verosimilitud

### Introducción

- Suponemos que antes de tomar la muestra disponemos de cierta información respecto al parámetro (o vector de parámetros) que se representa mediante una distribución inicial o **a priori**,  $p(\theta)$
- Después se toma una muestra  $X = \{x_1, x_2, \dots, x_n\}$ , y la probabilidad de obtener la muestra para cada valor posible del parámetro viene dada la función de probabilidad conjunta de las observaciones  $f(X|\theta) = l(X|\theta)$ , la función de verosimilitud
- A continuación combinamos según las reglas del cálculo de probabilidades estos dos elementos de información para obtener la distribución final o **a posteriori**, aplicando el teorema de Bayes

$$p(\theta|X) = \frac{f(X|\theta)p(\theta)}{\int f(X|\theta)p(\theta)d\theta}$$

- La distribución a posteriori contiene toda la información para hacer inferencia respecto al parámetro.

### Introducción

- Si se desea un estimador puntual, se tomará la media o la moda de dicha distribución; si se desea un intervalo de confianza, se tomará la zona que encierre una probabilidad fijada en dicha distribución.

- El denominador

$$m(X) = \int f(X|\theta)p(\theta)d\theta$$

- representa la distribución marginal de los datos, con independencia de los valores de los parámetros
- A esta distribución se la denomina, **distribución predictiva**, y es la media ponderada de la verosimilitudes  $f(X|\theta)$  por las probabilidades que la distribución a priori asigna a los posibles valores del parámetro
- Cuando observamos la muestra el denominador de la formula de Bayes, es una constante y el cálculo de  $p(\theta|X)$  se simplifica observando que esta constante tiene solo la función de normalizar el resultado como función de densidad.

### Introducción

- Sea  $k = m(X)$  para una muestra dada


$$p(\theta|X) = k \cdot l(X|\theta) \cdot p(\theta)$$

- La distribución posterior se calcula multiplicando para cada valor de  $\theta$  la verosimilitud por la distribución a priori.
- La constante  $k$  se determina al final con la condición de que  $p(\theta|X)$  sea una densidad de probabilidad.
- El teorema de Bayes se resume en  $\text{Posterior} \propto \text{Prior} \times \text{Verosimilitud}$ .
- La distribución Posterior es un compromiso entre la Prior y la Verosimilitud.

# Probabilidades y Estadística II, Tema 4

## Estimación Bayesiana


### Introducción





### Introducción

- En el caso particular en el  $p(\theta)$  se constante en el rango de valores en los cuales la verosimilitud es no nula, se dice que  $p(\theta)$  es no informativa



- La posterior está determinada por la verosimilitud

### Introducción

- Una ventaja adicional del enfoque Bayesiano es la posibilidad de procesar información secuencialmente.
- Tras calcular  $p(\theta|X)$  observamos una nueva muestra  $Y$  de la misma población, independiente de la muestra previa  $X$ .
- La distribución  $p(\theta|X)$  ahora tiene el rol de prior

$$p(\theta|XY) = k \cdot l(Y|\theta) \cdot p(\theta|X)$$

- Aplicando Bayes a la muestra ampliada  $XY$

$$p(\theta|XY) = k \cdot l(XY|\theta)p(\theta) = k \cdot l(Y|\theta) \cdot p(X|\theta) \cdot p(\theta)$$

- Automatiza la revisión del modelo del parámetro con nueva información

### Distribuciones a priori

Mayor dificultad práctica del enfoque Bayesiano:

Especificar la distribución a priori.

- Caso 1: La distribución a priori proviene de estudios empíricos anteriores y se conoce objetivamente.

Ejemplos:

- Determinar el porcentaje de elementos defectuosos en un proceso. Si se hizo un estudio similar hace unos meses, y suponiendo que las condiciones no han cambiado, tomaremos la distribución a posteriori del estudio anterior como distribución a priori del estudio actual.
- Tiempo medio que las personas de una zona dedican a navegar por Internet. Si conocemos un estudio de esta variable en otra zona de características similares; podemos tomar la distribución a posteriori del estudio como distribución a priori para nuestra zona.

### Distribuciones a priori

Mayor dificultad práctica del enfoque Bayesiano:

Especificar la distribución a priori.

- Caso 2: La información existente es subjetiva y no formalizada. Podemos comenzar por decidir el valor más probable del parámetro, que será la moda de la distribución, su rango de valores posibles y si la distribución es o no simétrica con relación a la moda.

Ejemplos:

- Lanzamiento de una moneda. Nuestra opinión a prior sobre la proporción de caras es 0.5 y ésta será la moda de la distribución.
- Edad de los estudiantes más veteranos de una Universidad. Si suponemos una Universidad sin programas para adultos pero con un amplio programa de tercer ciclo pensamos que el valor más probable (moda) es alrededor de 52 y que estamos seguros de que el estudiante más veterano deber tener más de 35 años y menos de 67.

### Distribuciones a priori

Mayor dificultad práctica del enfoque Bayesiano:  
Especificar la distribución a priori.

- Caso 3: La información a priori es pequeña con relación a la muestral. Podemos elegir una distribución a priori que refleje globalmente nuestra opinión, en particular la moda a priori y el rango de valores posibles, pero sin preocuparnos mucho del resto de los detalles. En estos casos elegiremos una distribución conjugada, analizaremos estas distribuciones en la sección siguiente.
- Caso 4: La información a priori es despreciable frente a la muestral, o no queremos tenerla en cuenta en el proceso de inferencia. En este caso podemos utilizar los métodos clásicos o utilizar el enfoque bayesiano con una distribución a priori no informativa o de referencia, que se analizan en la sección siguiente.

# ¿Comentarios y Preguntas?

GII-PYEII 2026

05/02/2026, CIG: [www.cig.fi.upm.es](http://www.cig.fi.upm.es)