

Lección 7, Probabilidades y Estadística II

Lección 14, semana 14, 12/05/2026

Juan A Fdez del Pozo (CIG-UPM)

May 8, 2026

Probabilidades y Estadística II

Inferencia Estadística

- Guía de Aprendizaje
- Datos generales, Competencias,

Resultados, Temario, Cronograma,
Evaluación, Recursos

Temario de la asignatura

1. Unidad Didáctica 1: Estimación del Modelo
 - 1.1. Tema 1: Introducción a la Inferencia
 - 1.2. Tema 2: Estimación puntual
 - 1.3. Tema 3: Estimación por intervalos
 - 1.4. Tema 4: Estimación Bayesiana
2. Unidad Didáctica 2: Contrastes de hipótesis
 - 2.1. Tema 5: Contrastes paramétricos
 - 2.2. Tema 6: Contrastes no paramétricos
3. Unidad Didáctica 3: Regresión lineal simple
 - 3.1. Tema 7: Regresión lineal simple

Práctica

Contenidos

- 5.1. Introducción: El problema de la regresión lineal simple
- 5.2. Métodos de mínimos cuadrados
- 5.3. Coeficiente de regresión
- 5.4. Coeficiente de correlación lineal
- 5.5. El contraste de regresión
- 5.6. Inferencias sobre los parámetros
- 5.7. Inferencias sobre la predicción
- 5.8. Los supuestos del modelo de regresión lineal
- 5.9. Un ejemplo donde no se cumplen los supuestos
- 5.10. Un ejemplo con R

Introducción

→ **El problema de la regresión lineal simple:**

El objetivo de un modelo de regresión lineal simple es tratar de explicar la relación que existe entre

- un conjunto de variables independientes (variables explicativas) $X_1, \dots, X_n$
- y
- una variable dependiente (variable respuesta) Y



mediante una función sencilla e interpretable, una relación lineal, la recta de regresión, bajo ciertas hipótesis.

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Ejemplo: El problema de la regresión lineal simple

- En la muestra de la miel vamos a ver si existe relación lineal entre la acidez libre ($AcLib$) y la acidez total ($AcTot$)
- Para ver si un modelo de regresión lineal tiene sentido, comenzamos dibujando un diagrama de dispersión (X, Y)




Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Introducción: El problema de la regresión lineal simple

Mediante las técnicas de regresión de una variable Y sobre una variable X , buscamos una función que sea una buena aproximación de una nube de puntos (x_i, y_i) , mediante una curva del tipo: $\hat{Y} = f(X)$



El modelo de regresión lineal simple tiene la siguiente expresión:


$$Y = \alpha + \beta X + \epsilon$$

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Introducción: El problema de la regresión lineal simple

- α es la ordenada en el origen (el valor que toma Y cuando X vale 0),
- β es la pendiente de la recta (e indica cómo cambia Y al incrementar X en una unidad) y
- ϵ una variable que incluye un conjunto grande de factores, cada uno de los cuales influye en la respuesta sólo en pequeña magnitud, a la que llamaremos error



X e Y son variables aleatorias, por lo que no se puede establecer una relación lineal exacta entre ellas

Introducción: Método de mínimos cuadrados

Para hacer una estimación del modelo de regresión lineal simple, trataremos de buscar una recta de la forma:

$$\hat{Y} = \hat{\alpha} + \hat{\beta} \cdot X = a + b \cdot X$$

de modo que se ajuste a la nube de puntos

Para esto utilizaremos el método de mínimos cuadrados. Consiste en minimizar la suma de los cuadrados de los errores:

$$S(a, b) = \sum e_i^2 = \sum (y_i - \hat{y}_i)^2 = \sum (y_i - (a + b \cdot x_i))^2$$


→ la suma de los cuadrados de las diferencias entre los valores reales observados (y_i) y los valores estimados ($\hat{y}_i$).

$$\frac{\partial S}{\partial a} = 0; \frac{\partial S}{\partial b} = 0$$

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Introducción: Método de mínimos cuadrados



Las expresiones que se obtiene para a y b son las siguientes:

$$a = \bar{y} - b\bar{x}; b = \frac{S_{XY}}{S_X^2}$$

donde $\bar{x} = \frac{\sum x_i}{n}$, $\bar{y} = \frac{\sum y_i}{n}$, son la media muestrales de X y Y , respect,

$S_X^2 = \frac{\sum (x_i - \bar{x})^2}{n}$ es la varianza muestral de X y

$S_{XY} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{n}$ es la covarianza muestral de X e Y

El valor b , coeficiente de regresión de Y sobre X , lo denotamos por $b_{X/Y}$

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Introducción: Método de mínimos cuadrados

Ejemplo:

Los estadísticos descriptivos anteriores para las variables $AcTot$ y $AcLib$ (acidez total y acidez libre) son los siguientes:


$$\bar{y} = 37.998, \bar{x} = 33.8727,$$

$$S_X^2 = 90.786, S_Y^2 = 85.459, S_{XY} = 89.978$$

La recta de regresión ajustada es la siguiente:

$$\hat{Y} = 4.469 + 0.990 \cdot X$$

, donde Y es la acidez total y X es la acidez libre.



Método de mínimos cuadrados

- Para calcular la recta de regresión de X sobre Y se hace aproximando X por $\hat{X}$, del modo

$$\hat{X} = a + b \cdot Y$$

donde

$$a = \bar{y} - b\bar{x}; \quad b = \frac{S_{XY}}{S_Y^2}$$

- Es incorrecto despejar X de la ecuación $\hat{Y} = a + b \cdot X$ para calcular la recta de regresión de X sobre Y
- Observación: La recta de regresión pasa siempre por el centro de gravedad de la nube de puntos, es decir, por el punto $(\bar{X}, \bar{Y})$

Método de mínimos cuadrados

Ejemplo: De una determinada empresa se conocen los siguientes datos, referidos al volumen de ventas (en millones de euros) y al gasto en publicidad (en miles de euros) de los últimos 6 años:

Volumen de ventas (mill. €)	Gastos publicidad (miles €)
10	16
15	32
20	48
22	56
30	64
32	80


- ¿Existe relación lineal entre las ventas de la empresa y sus gastos en publicidad? Razona la respuesta.
- Obtener las rectas de regresión mínimo cuadrático.
- ¿Qué volumen de ventas de la empresa se podría esperar en un año que se gaste de publicidad 60000 euros? ¿Y para un gasto en publicidad de 200000 euros?

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Método de mínimos cuadrados

- Calculamos el coeficiente de determinación lineal para obtener una medida descriptiva del grado de asociación lineal que existe entre las variables.



La expresión del coeficiente de determinación es:

$$r^2 = \frac{S_{XY}^2}{S_X^2 S_Y^2} = \frac{24964}{435.55 \cdot 59.92} = 0.956$$

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Método de mínimos cuadrados

$$b = \frac{S_{XY}}{S_X^2} = \frac{158}{435.55} = 0.363. \quad a = \bar{y} - b\bar{x} = 21.5 - 0.363 * 49.33 = 3.603$$

$$d = \frac{S_{XY}}{S_Y^2} = \frac{158}{59.92} = 2.637. \quad c = \bar{x} - d\bar{y} = 49.33 - 2.637 * 21.5 = -7.365$$

Aplicándolas a este problema obtenemos las rectas de regresión:

$$Y = 3.603 + 0.363 \cdot X \quad X = -7.365 + 2.637 \cdot Y$$

- Para realizar la predicción del volumen de ventas utilizamos la recta de regresión que tienen las ventas en función de los gastos en publicidad. Para un gasto en publicidad de 60000 euros obtendremos un volumen de ventas de $Y = 3.603 + 0.363 \cdot 60 = 25.383$ millones de euros. Si el gasto es de 200 millones de euros no podemos utilizar la recta de regresión puesto que el valor 200 está fuera del recorrido del gasto en publicidad. Si sustituimos por un valor de 76203 millones de euros, pues las rectas sólo son válidas dentro del rango o para valores próximos a los extremos del recorrido.

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

El coeficiente de regresión

El coeficiente de regresión $b_{X/Y}$ nos da información sobre el comportamiento de la variable Y frente a la variable X , de manera que:

- Si $b_{X/Y} = 0$, *forall* X la variable Y es constante (es decir, no cambia)
- Si $b_{X/Y} > 0$, indica que al aumentar el valor de X , aumenta el valor de Y
- Si $b_{X/Y} < 0$, indica que al aumentar el valor de X , el valor de Y disminuye

Ejemplo: El coeficiente de regresión

En el ajuste de regresión lineal de la $AcTot$ sobre la $AcLib$ se obtenía el modelo:

$$\hat{Y} = 4.469 + 0.990 \cdot X$$

donde Y es la $AcTot$ y X es la $AcLib$

$b_{X/Y} = 0.99 > 0$ y esto indica que al aumentar X aumenta Y

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

El coeficiente de correlación lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

El coeficiente de correlación lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

El coeficiente de correlación lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

El coeficiente de correlación lineal

El contraste de regresión

El contraste de regresión

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Inferencias para los parámetros

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Inferencias para los parámetros

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Inferencias para los parámetros

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Inferencias sobre la predicción

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Inferencias sobre la predicción

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Inferencias sobre la predicción

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Inferencias sobre la predicción

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Los supuestos del modelo de regresión lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Los supuestos del modelo de regresión lineal

Los supuestos del modelo de regresión lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Los supuestos del modelo de regresión lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Los supuestos del modelo de regresión lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Los supuestos del modelo de regresión lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Los supuestos del modelo de regresión lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Los supuestos del modelo de regresión lineal

Los supuestos del modelo de regresión lineal

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Un ejemplo en el que no se cumplen los supuestos

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Un ejemplo en el que no se cumplen los supuestos

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Un ejemplo en el que no se cumplen los supuestos

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Un ejemplo en el que no se cumplen los supuestos

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Un ejemplo en el que no se cumplen los supuestos

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Un ejemplo con R

Ejercicio 1

- Con el fin de estudiar la relación entre la velocidad de procesamiento y la temperatura de un procesador, se ha compilado un programa determinado a diferentes temperaturas.

Se han obtenido los datos mostrados en la tabla:

Temperatura en $^{\circ}\text{C}$	17	18	19	20	21	22
Tiempo en ms	36,76	37,86	38,5	41	45,11	49,25

Obtener la recta de regresión que permita predecir, a partir de la temperatura del procesador, el tiempo de procesamiento.

- Para conseguir predecir el tiempo de procesamiento a partir de la temperatura del procesador, se debe tomar como variable dependiente
 Y = tiempo de procesamiento y como variable independiente
 X = temperatura del procesador.

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Ejercicio 1

- A continuación se realizan algunos cálculos a partir de los datos:

$$\begin{aligned}\bar{X} &= \frac{\sum x_i}{n} = \frac{117}{6} = 19,5 & \hat{\sigma}_X^2 &= \frac{\sum x_i^2}{n} - \bar{X}^2 = 2,9166 \\ \bar{Y} &= \frac{\sum y_i}{n} = \frac{248,48}{6} = 41,4133 & \hat{\sigma}_Y^2 &= \frac{\sum y_i^2}{n} - \bar{Y}^2 = 19,6719 \\ \text{Cov}(X, Y) &= \frac{\sum x_i y_i}{n} - \bar{X}\bar{Y} = 7,225\end{aligned}$$

- Los estimadores de los parámetros β_0 y β_1 son, respectivamente, los siguientes:

$$\begin{aligned}\hat{\beta}_1 &= \frac{\text{Cov}(X, Y)}{\hat{\sigma}_X^2} = \frac{7,225}{2,9166} = 2,477 \\ \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{X} = 41,4133 - 2,477 \cdot 19,5 = -6,89\end{aligned}$$

- Con lo que la recta de regresión es: $\hat{Y}_i = -6,9 + 2,477 \cdot x_i$

Ejercicio 2

- Con los datos del ejemplo 1, construir un intervalo de confianza al 90% para el parámetro β_1 .
- El intervalo de confianza para β_1 con $\alpha = 0.1$ es

$$\left(\hat{\beta}_1 - t_{4;0,05} \frac{\hat{S}_R}{\sqrt{n\hat{\sigma}_X^2}}, \hat{\beta}_1 + t_{4;0,05} \frac{\hat{S}_R}{\sqrt{n\hat{\sigma}_X^2}} \right)$$

- De la tabla de la t de Student se obtiene el percentil 95, $t_{4;0.005} = 2.132$. Además, se necesita calcular la varianza residual $\hat{S}_R^2$.

$$\hat{S}_R^2 = \frac{\sum e_i^2}{n-2} = \frac{\sum (Y_i - \hat{Y}_i)^2}{n-2}$$

Ejercicio 2

- A partir de los datos y de la recta de regresión obtenida en el ejemplo 1, se obtienen los valores de la tabla 2 y sustituyendo en la fórmula anterior, la varianza residual es $\hat{S}_R^2 = 2.6581$ y su raíz $\hat{S}_R = 1.63$.

x_i	17	18	19	20	21	22
Y_i	36,76	37,86	38,5	41	45,11	49,25
$\hat{Y}_i$	35,219	37,696	40,173	42,65	45,127	47,604
$(Y_i - \hat{Y}_i)^2$	2,374681	0,026896	2,798929	2,7225	0,000289	2,709316

- Con los valores obtenidos y los calculados en el ejemplo 1, se tiene que el intervalo de confianza para β_1 , con una confianza del 90% es (1.64627, 3.30773)

Ejercicio 3

- Continuando con el ejemplo 1, ¿se podría prescindir del término independiente en la recta de regresión?
- Se debe contrastar si se puede suponer $\beta_0 = 0$.
- Se resuelve mediante el siguiente contraste de hipótesis bilateral:

$$H_0 : \beta_0 = 0; H_1 : \beta_0 \neq 0;$$

- Se utiliza como medida de discrepancia la variable pivote obtenida para calcular el intervalo de confianza para β_0 , particularizando con el valor especificado en la hipótesis nula, que es $\beta_0 = 0$.

$$d = \frac{\hat{\beta}_0 - \beta_0}{\sqrt{\frac{\hat{S}_R^2}{n} \left(1 + \frac{\bar{X}^2}{\hat{\sigma}_X^2}\right)}} = \frac{\hat{\beta}_0}{\sqrt{\frac{\hat{S}_R^2}{n} \left(1 + \frac{\bar{X}^2}{\hat{\sigma}_X^2}\right)}} \sim t_{n-2} \text{ si } H_0 \text{ es cierta}$$

Ejercicio 3

- Con los valores obtenidos en el ejemplo 1 y la varianza residual calculada en el ejemplo 2, la discrepancia observada es $\hat{d} = -0.903$. Como no se indica un nivel de significación, hay que calcular el nivel crítico o *p* – *valor*:

$$p = P(|d| \geq |\hat{d}|/H_0 \text{ cierta}) = P(|d| \geq 0,903/d \sim t_4) = 2P(t_4 \geq 0,903)$$

- A partir de la tabla proporcionada de la *t* de Student, habría que interpolar entre los valores $t_{4;0.1} = 1.533$ y $t_{4;0.5} = 0$ (este último valor se conoce porque la distribución *t* de Student es simétrica respecto al origen) obteniendo un *p* – *valor* aproximado: $p \approx 2 \cdot 0.2644 = 0,5288$
- Como el *p* – *valor* es superior a 0.2, no existen evidencias para rechazar la hipótesis nula y, por tanto, se puede asumir que el término independiente β_0 es 0, y se puede prescindir de dicho término en la ecuación de regresión.

Ejercicio 4

- Dentro de la Gestión de Proyectos Software, uno de los modelos de estimación relaciona de forma lineal las variables $Y = \text{EFFORT}$ (esfuerzo para realizar el sistema en cuestión medido en personas/mes) y $X = \text{LOC}$ (número de líneas de código a desarrollar, en miles de líneas). Si se dispone de los datos recogidos en la tabla 4:

LOC	30	32	31	37	29	39
EFFORT	82	90	83	98	80	103

- Calcular la Recta de Regresión que permita predecir la variable EFFORT en función de la variable LOC y obtener el coeficiente de correlación lineal.
- Construir la tabla ANOVA y contrastar la bondad del modelo con una confianza del 95%.
- Contrastar la hipótesis de que al aumentar en 1000 el número de líneas de código, aumentan en 2 las personas necesarias. Nivel de confianza del 98%.
- Predecir el esfuerzo para realizar un sistema que necesita 35000 líneas de código para su desarrollo, dando un intervalo de confianza al 90%.

Ejercicio 4

- Primero se realizan algunos cálculos a partir de los datos:

$$\begin{aligned}\bar{X} &= \frac{\sum x_i}{n} = \frac{198}{6} = 33 & \hat{\sigma}_X^2 &= \frac{\sum x_i^2}{n} - \bar{X}^2 = 13,66 \\ \bar{Y} &= \frac{\sum y_i}{n} = \frac{536}{6} = 89,33 & \hat{\sigma}_Y^2 &= \frac{\sum y_i^2}{n} - \bar{Y}^2 = 73,88 \\ \text{Cov}(X, Y) &= \frac{\sum x_i y_i}{n} - \bar{X} \bar{Y} = 31,44\end{aligned}$$

- Para obtener la recta de regresión pedida, se calculan los estimadores de los parámetros β_0 y β_1 , que son, respectivamente, los siguientes:

$$\begin{aligned}\hat{\beta}_1 &= \frac{\text{Cov}(X, Y)}{\hat{\sigma}_X^2} = \frac{31,44}{13,66} = 2,29 \\ \hat{\beta}_0 &= \bar{Y} - \hat{\beta}_1 \bar{X} = 89,33 - 2,29 \cdot 33 = 13,76\end{aligned}$$

- Con lo que la recta de regresión es: $\hat{Y}_i = 2.29 \cdot x_i + 13.76$ y el coeficiente de correlación lineal es

$$r = \frac{\text{Cov}(X, Y)}{\hat{\sigma}_X \hat{\sigma}_Y} = \frac{31,44}{\sqrt{13,66 \cdot 73,88}} = 0,99$$

Ejercicio 4

- Se obtienen primero algunos de los elementos de la tabla ANOVA.

$$VT = n\hat{\sigma}_Y^2 = 6 \cdot 73,88 = 443,28$$

$$VE = \hat{\beta}_1^2 n \hat{\sigma}_X^2 = 2,29^2 \cdot 6 \cdot 13,66 = 429,8064$$

$$VNE = VT - VE = 443,28 - 429,8064 = 13,4736$$

- Tabla ANOVA:

Variación	Suma de cuadrados	Grados de libertad	Cociente
VE	429,8064	1	429,8064
VNE	13,4736	4	$3,3684 = \hat{S}_R^2$
VT	443,28	5	

Ejercicio 4

- Para contrastar la bondad del modelo al 95% de confianza, se debe resolver el siguiente contraste con $\alpha = 0.05$:

$$H_0 : \beta_1 = 0; H_1 : \beta_1 \neq 0;$$

- A partir de la tabla ANOVA se obtiene que la discrepancia observada es

$$\hat{F}^* = \frac{429,8064}{3,3684} = 127,5995$$

- Como $F^* \sim F_{1,4}$ si H_0 es cierta y el contraste se resuelve a una cola, se busca en la tabla de la F de Snedecor el valor $F_{1,4;0.05} = 7.709$ que define la región crítica o de rechazo que es $(7.709; \infty)$. Como $\hat{F}^* > 7.709$, existen evidencias para rechazar la hipótesis nula y, por tanto, la pendiente de la recta es significativamente distinto de cero y existe relación lineal entre ambas variables.

Ejercicio 4

- Como el coeficiente β_1 representa el aumento (o disminución) de la variable Y cuando X aumenta en una unidad, se pide comprobar si se puede aceptar $\beta_1 = 2$. Recuerdese que como X viene dada en miles de líneas de código, un aumento de 1000 líneas equivale a aumentar X en 1. El contraste a resolver es el siguiente:

$$H_0 : \beta_1 = 2; H_1 : \beta_1 \neq 2;$$

- La medida de discrepancia que se debe utilizar es

$$d = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{S}_R^2}{n\hat{\sigma}_X^2}}} = \frac{\hat{\beta}_1 - 2}{\sqrt{\frac{\hat{S}_R^2}{n\hat{\sigma}_X^2}}} \sim t_{n-2} = t_4 \text{ si } H_0 \text{ es cierta}$$

- Sustituyendo, la discrepancia observada es $\hat{d} = 1.502$. Como el nivel de significación es $\alpha = 0.02$, se busca en la tabla correspondiente el valor $t_{4;0.01} = 3.747$, y la región de rechazo es $(-\infty; -3.747) \cup (3.747; \infty)$.

Ejercicio 4

- El valor observado para la discrepancia está fuera de dicha región, con lo que no existe evidencia para rechazar H_0 .
- Obsérvese que la varianza residual $\hat{S}_R^2$ se había obtenido en la tabla ANOVA, pero también se podía haber obtenido a partir de los residuos y a partir del coeficiente de correlación lineal mediante la siguiente fórmula ya vista con anterioridad.

$$\hat{S}_R^2 = \frac{(1 - r^2)n\hat{\sigma}_Y^2}{n - 2}$$

- Este contraste se puede resolver por medio de un intervalo de confianza. Al 98%, el intervalo de confianza que se obtiene para β_1 es el siguiente:

$$\left(\hat{\beta}_1 \mp t_{4;0,01} \frac{\hat{S}_R}{\sqrt{n\hat{\sigma}_X^2}} \right) = (1,56; 3,013)$$

- Como este intervalo contiene el valor 2, no existe evidencia suficiente para rechazar que β_1 pueda ser igual a 2 con $\alpha = 0.02$.

Ejercicio 4

- El intervalo de confianza para una predicción es

$$\left(\hat{Y}_h \mp t_{n-2, \frac{\alpha}{2}} \hat{S}_R \sqrt{1 + V_{hh}} \right) \quad V_{hh} = \frac{1}{n} + \frac{(x_h - \bar{X})^2}{\sum (x_i - \bar{X})^2} = \frac{1}{n} + \frac{(x_h - \bar{X})^2}{n \hat{\sigma}_x^2}$$

- En este caso $x_H = 35$ y la estimación puntual de la predicción es, sustituyendo en la recta de regresión obtenida en el apartado a), $\hat{Y}_H = 93.91$ (aproximadamente 94 personas/mes).
- Como se pide una confianza del 90%, se tiene $\alpha = 0.1$ y buscando en la tabla de la t de Student, $t_{4;0.05} = 2.132$.
- Sustituyendo se obtiene $V_{HH} = 0.21547$ y el intervalo de confianza al 90% para Y_H es $(89.5961, 98.2239)$

Ejercicio 5

- En una investigación sobre la relación entre el tráfico X (en miles de automóviles cada 24 horas) y el contenido en plomo Y de la corteza de los árboles cerca de la autopista (en $\mu g/g$ de peso seco), se obtuvieron los datos de la tabla siguiente:

x	8.3	8.3	12.1	12.1	17	17	17	24.3	24.3	24.3	33.6
y	227	312	362	521	640	539	728	945	738	759	1263

- Calcular la relación inicial que permita predecir, a partir del tráfico, el contenido en plomo en la corteza de un árbol.
¿El coeficiente ρ es?
- ¿En cuánto aumentará el contenido en plomo de un árbol cerca de la autopista al aumentar en un punto el tráfico, es decir, al aumentar en 1000 el número de automóviles?

Ejercicio 5

- Con un 95% de confianza, ¿entre qué valores oscilará el aumento en el contenido en plomo cuando se incrementa en la autopista el tráfico en una unidad?
- Contrastar al 90% la bondad del modelo lineal.
- Contrastar al 99% la hipótesis de que un aumento en un punto en el tráfico provoca un incremento de 40 unidades en el contenido en plomo en la corteza de los árboles. Calcular además el nivel crítico.
- Con un 95% de confianza, ¿entre qué valores oscilará el contenido en plomo de la corteza de los árboles cerca de una autopista con un tráfico de 20000 automóviles cada 24 horas?
- Con una confianza del 99%, determinar si la desviación típica de la perturbación es superior a 50.

Ejercicio 5.1

- Ajustamos la recta de regresión: $\hat{Y}_i = \hat{\beta}_0 + \hat{\beta}_1 \cdot X_i = \bar{Y} + \hat{\beta}_1 \cdot (X_i - \bar{X})$
- Hacemos los cálculos a partir de los datos que nos dan:
 $\sum x_i = 198.3; \sum x_i^2 = 4108.03; \sum y_i = 7034; \sum y_i^2 = 5390382;$
 $\sum x_i \cdot y_i = 149354.4$
 $\bar{x} = \frac{\sum x_i}{n} = 18.027; V(x) = \frac{\sum x_i^2}{n} - \bar{x}^2 = 56.76;$
 $\bar{y} = \frac{\sum y_i}{n} = 639.45; V(y) = \frac{\sum y_i^2}{n} - \bar{y}^2 = 81138.4248;$
 $Cov(x, y) = \frac{\sum x_i \cdot y_i}{n} - \bar{x} \cdot \bar{y} = 2050.3; \text{ y el coef } \hat{\beta}_1 = \frac{Cov(x, y)}{V(x)} = 36.18$
- la Recta de Regresión es:
 $\hat{Y}_i = 639.45 + 36.18 \cdot (X_i - 18.027) = 36.18 \cdot X_i - 12.7668$
- El coeficiente de correlación lineal es $\rho = \frac{Cov(X, Y)}{\sigma_X \cdot \sigma_Y} = \frac{2050.3}{7.528 \cdot 284.848} = 0.956$, Su valor es muy próximo a 1, lo que indica una correlación alta y positiva entre las variables.
- El coeficiente de determinación del modelo es $R^2 = r^2 = 0.9142$ lo que indica que el modelo explica el 91.42% de la variabilidad total.

Ejercicio 5.2, 5.3

- ¿En cuánto aumentará el contenido en plomo de un árbol cerca de la autopista al aumentar en un punto el tráfico, es decir, al aumentar en 1000 el número de automóviles?

En β_1 , cuya estimación puntual es 36.18.

- Con un 95% de confianza, ¿entre qué valores oscilará el aumento en el contenido en plomo cuando se incrementa en la autopista el tráfico en una unidad? Nos piden un intervalo de confianza al 95% para β_1 donde

$$T = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{S}_R^2}{nV(X)}}} \sim t_{n-2}$$

con lo que el IC-95% para β_1 es

$$\left(\hat{\beta}_1 \mp t_{n-2, 0.025} \frac{\hat{S}_R}{\sqrt{nV(X)}} \right)$$

Ejercicio 5.3

- Como $n = 11$, $t_{9;0.025} = 2.262$ (tablas t-Student)
- Falta calcular la varianza residual $\hat{S}_R^1 = \frac{\sum e_i^2}{n-2}$. Se puede obtener a partir de los

$$\hat{S}_R^2 = \frac{(1 - r^2)nV(Y)}{n - 2} = 8508.716 \Rightarrow \hat{S}_R = 92.24$$

- el intervalo de confianza para la pendiente de la recta con un nivel de confianza del 95% es (27.8232, 44.5368)

Ejercicio 5.4

- Contrastar al 90% la bondad del modelo lineal. Debemos realizar el siguiente contraste sobre la pendiente de la recta:

$$H_0 : \beta_1 = 2; H_1 : \beta_1 \neq 2;$$

- con un nivel de significación $\alpha = 0.1$. La medida de discrepancia es

$$d = \frac{\hat{\beta}_1 - \beta_1}{\sqrt{\frac{\hat{S}_R^2}{nV(X)}}} = \frac{\hat{\beta}_1 - 0}{\sqrt{\frac{\hat{S}_R^2}{nV(X)}}} \sim t_{n-2} \text{ si } H_0 \text{ es cierta}$$

- Sustituyendo obtenemos $\hat{d} = \frac{36.18}{3.6944} = 9.7932$.
- De las tablas de la t – *Student* obtenemos $t_{9;0.05} = 1.833$, con lo que la región de rechazo es $(-\infty, -1.833) \cup (1.833, \infty)$.
- Como $\hat{d} > 1.833$, existe evidencia suficiente para rechazar H_0 y por tanto $\beta_1 \neq 0$ y el modelo es lineal.
- También lo podemos resolver a partir del intervalo de confianza al 90% para β_1 , comprobando si $\beta_1 = 0$ está o no dentro de ese intervalo.

Ejercicio 5.4

- Otra posibilidad es realizar el contraste utilizando el análisis de la varianza. Ahora las hipótesis a contrastar se expresan de la siguiente forma:

$$H_0 : VE \ll VNE; H_1 : VE \gg VNE$$

- En este caso, la medida de discrepancia es:

$$F = \frac{\hat{\beta}_1^2 n V(X)}{\hat{S}_R^2} \sim F_{1, n-2} \text{ si } H_0 \text{ es cierta}$$

- Sustituyendo obtenemos $\hat{F} = 95.9$ y en las tablas de la F de Snedecor encontramos $F_{1,9;0.1} = 3.3603$, con lo que la región de rechazo es $(3.3603, \infty)$ y como $F > 3.3603$ rechazamos H_0 y, por tanto, rechazamos que $\beta_1 = 0$ y entonces existe relación significativa entre X e Y

Ejercicio 5.5

- Contrastar al 99% la hipótesis de que un aumento en un punto en el tráfico provoca un incremento de 40 unidades en el contenido en plomo en la corteza de los árboles. Calcular además el nivel crítico.

Ahora debemos resolver el siguiente contraste con un nivel de significación $\alpha = 0.01$:

$$H_0 = \beta_1 = 40$$

$$H_1 = \beta_1 \neq 40$$

$$d = \frac{\hat{\beta}_1 - 40}{\sqrt{\frac{\hat{S}_R^2}{nV(X)}}} \sim t_{n-2=9} \text{ si } H_0 \text{ es cierta}$$

$$\hat{d} = \frac{-3.82}{3.6944} = -1.034$$

Ejercicio 5.5

- Al ser $\alpha = 0.01$, necesitamos el valor $t_{9,0.005} = 3.25$, para determinar la región de rechazo y no rechazo.
- En este caso, la región de no rechazo es $(-3.25, 3.25)$ y como $\hat{d}$ está en dicha región ($\hat{d} \in (-3.25, 3.25)$), no existe evidencia para rechazar H_0 .
- El nivel crítico o p-valor es el siguiente:

$$p = P(|d| \geq |\hat{d}|/H_0 \text{ cierta}) = P(|d| \geq |-1.034|/d \sim t_9) =$$

$$P(|t_9| \geq 1.034) = 2 \cdot P(t_9 \geq 1.034) \approx 2 \cdot 0.1698 = 0.3396$$

- Como el p -valor es mayor que 0.2, no rechazamos la hipótesis de que la pendiente de la recta es 40 para cualquier nivel de significación razonable.

Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Ejercicio 5.6



Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Ejercicio 5.7



Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Ejercicio 6



Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Ejercicio 7



Probabilidades y Estadística II, Tema 7

Regresión lineal simple

Ejercicio 8



¿Comentarios y Preguntas?

GII-PYEII 2026

05/02/2026, CIG: www.cig.fi.upm.es